

선형대수학팀

3팀

윤지영
이지윤
이수린
임지훈
채희지

INDEX

1. 공간(Space)
2. 노름과 내적
3. 직교성
4. 투영 (Projection)
5. 회귀적용

1

공간 (Space)

1

공간 (Space)

벡터공간 (Vector Space)

벡터공간

여러 벡터들이 모여 형성하는 공간

벡터 원소들끼리 서로 더하거나 주어진 배수로 늘이거나 줄일 수 있는 공간



선형부분공간 (Subspace)

벡터공간 안의 몇 가지 벡터의 집합으로 이루는 벡터공간 안의 또 다른 부분 벡터공간

1 공간 (Space)

선형부분공간 (Subspace)


선형부분공간 (Subspace)

벡터공간 안의 몇 가지 벡터의 집합으로 이루는 벡터공간 안의 또 다른 부분 벡터공간



선형부분공간을 만족하는 조건

- ① **0**벡터(원점)가 존재
- ② 선형부분공간에 있는 벡터에 다른 벡터를 더했을 때, 그 **합**도 선형부분공간에 존재
- ③ 선형부분공간에 있는 벡터에 스칼라를 곱했을 때, 그 **곱**도 선형부분공간에 존재



1

공간 (Space)

선형부분공간을 만족하는 예시

영벡터 (Zero Vector)

차원에 상관없이 원소가 **영벡터 1개**인 벡터공간은 R^n 의 가장 작은 subspace

영벡터끼리 더해도 영벡터

영벡터에 어떤 스칼라 값을 곱하든 영벡터



이 집합은 벡터 연산에 닫혀 있음

벡터의 연산 법칙

$$\text{상수배: } c\mathbf{v} = \begin{bmatrix} ca \\ cb \end{bmatrix} \quad \text{덧셈: } \mathbf{v} + \mathbf{w} = \begin{bmatrix} a + c \\ b + d \end{bmatrix} \quad \text{뺄셈: } \mathbf{v} - \mathbf{w} = \begin{bmatrix} a - c \\ b - d \end{bmatrix}$$

벡터의 연산 법칙에 대한 자세한 내용은 선대팀 1주차 참고




1

공간 (Space)

선형부분공간을 만족하는 예시

원점을 지나는 하나의 직선 위에 있는 벡터들



원점을 지나는 하나의 직선 위의 벡터들은 **덧셈/곱**으로 나머지 성분을 만들 수 있음



3차원 공간에서 원점을 지나는 평면 (plane) 또한

R^3 의 subspace 평면 안에 있는 벡터끼리 더하든 곱하든 **그 평면 내에서만 존재**

1

공간 (Space)

선형부분공간 (Subspace)

원점을 지나는 하나의 직선 위에 있는 벡터들



원점을 지나야만 하는 이유는?

어떤 벡터의 0 스칼라 곱은 영벡터가 됨

∴ 모든 subspace에는 영벡터가 포함되어 있음

원점을 지나는 하나의 직선 위의 벡터들은 어떤 한 성분의 스칼라 곱이 나머지 성분을 만들 수 있음



3차원 공간에서 원점을 지나는 평면 (plane) 또한


R^3 의 subspace 평면 안에 있는 벡터끼리 더하든 곱하든 그 평면 내에서만 존재

1 공간 (Space)

선형부분공간이 아닌 경우

선형부분공간을
만족하는 조건

- ① **0**벡터(원점)가 존재
- ② 선형부분공간에 있는 벡터에 다른 벡터를 더했을 때, 그 **합**도 선형부분공간에 존재
- ③ 선형부분공간에 있는 벡터에 스칼라를 곱했을 때, 그 **곱**도 선형부분공간에 존재



축을 포함한 1사분면은 **원점 포함**

1사분면 내의 벡터끼리 **더하면** 1사분면에 위치


조건 ①, ② 만족

1 공간 (Space)

선형부분공간이 아닌 경우

선형부분공간을
만족하는 조건

- ① **0**벡터(원점)가 존재
- ② 선형부분공간에 있는 벡터에 다른 벡터를 더했을 때, 그 **합**도 선형부분공간에 존재
- ③ 선형부분공간에 있는 벡터에 스칼라를 곱했을 때, 그 **곱**도 선형부분공간에 존재



1사분면 내의 벡터에 **음수** 스칼라를 곱하면 1사분면을 벗어남

조건 ③ 만족 X → 곱셈연산에 닫혀있음

1

공간 (Space)

열공간 (Column space)

열공간 (Column space)

행렬의 열들의 선형 결합을 통해 만들 수 있는 vector space

EXAMPLE

$$\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \xrightarrow{Ax=b} x \begin{bmatrix} 2 \\ -1 \end{bmatrix} + y \begin{bmatrix} -1 \\ 2 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$

모든 b 에 대해서 x solution이 존재
 b_1, b_2 가 무엇이든 x, y 구할 수 있음

1

공간 (Space)

열공간 (Column space)

열공간 (Column space)

행렬의 열들의 선형 결합을 통해 만들 수 있는 vector space



모든 b 에 대해 x 집합 존재

EXAMPLE

행렬 A 의 두 개의 column의 linear combination으로

모든 R^2 의 공간에 있는 벡터 만들 수 있다는 것을 의미

모든 b 에 x solution이 존재

b_1, b_2 가 무엇이든 x, y 구할 수 있음

1

공간 (Space)

열공간 (Column space)

열공간 (Column space)

행렬의 열들의 선형 결합을 통해 만들 수 있는 vector space



EXAMPLE

어떤 b 에 대해서 solution 구하지 못할 수 있음



$$\begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} \xrightarrow{Ax = b} x \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} + y \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

b vector의 첫 번째 성분 = 세 번째 성분

→ x, y 값을 구할 수 있음


1

공간 (Space)

열공간 (Column space)

열공간 (Column space)

행렬의 열들의 선형 결합을 통해 만들 수 있는 vector space



우리가 구할 수 있는 b는

linear combination으로 만들 수 있는 것 뿐

1

공간 (Space)

Subspace의 종류

 $Ax=b$ 가 있다벡터 b 가 $\text{col}(A)$ 에 있다모든 b 에 대해 해를 갖는다

$$\text{Col}(A) = \mathbb{R}^n$$

모든 b 에 대해 해 X

$$\text{Col}(A)$$

 $= n$ 보다 작은 차원의 subspace

1

공간 (Space)

영공간 (Null Space)

영공간 (*Null space*)

$Ax=0$ 을 만족시키는 모든 x solutions의 집합

$$Ax = 0 \rightarrow \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

A의 어떤 행렬의 Null space에 **영벡터**가 무조건 포함

1

공간 (Space)

영공간 (Null Space)

영공간 (*Null space*)

$Ax=0$ 을 만족시키는 모든 x solutions의 집합

$$Ax = 0 \rightarrow \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

A의 어떤 행렬의 Null space에 영벡터가 무조건 포함

⋮

영벡터를 제외한



행렬 A의 column들의 어떤 linear combination이 영벡터를 만들까?

1

공간 (Space)

영공간 (Null Space)

두 column의 linear combination으로 나머지 하나의 벡터를 만들 수 있으면

0벡터 말고도 다른 해 $[x, y, z]$ 찾을 수 있음

$$x \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} + y \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} + z \begin{bmatrix} 1 \\ 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \longrightarrow x \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} + y \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} = -z \begin{bmatrix} 1 \\ 1 \\ 2 \end{bmatrix}$$

⋮

해 벡터들은 선형부분공간의 조건 만족

(① 해에 0벡터가 포함 ② 상수배나 해벡터끼리의 합도 해의 집합에 포함되기 때문)



Null space도 선형부분공간 중 하나

1

공간 (Space)

행공간과 Left Null Space

행공간 (*Row Space*)

행렬의 row의 linear combination 을 통해 만들 수 있는 subspace



A^T 의 column space = A 의 row space

Left Null Space

A^T 의 Null space

1

공간 (Space)


함수의 개념 적용

선형변환 = 함수



함수: 정의역의 원소들이 함수를 통해 치역에 대응

선형대수: 행공간과 영공간의 원소들이 행렬을 통해 열공간으로 매핑



$$f : X \rightarrow Y$$

1

공간 (Space)

선형독립과 선형종속

n개의 벡터에 대한 선형결합

$$c_1 x_1 + c_2 x_2 + \dots + c_n x_n = 0$$

선형독립 (*Linearly Independent*)

상수 c 가 모두 0인 경우를 제외한 어떠한 c_i 의 조합으로 식이 성립되지 않는 경우

$$c_1 = c_2 = \dots = c_n = 0$$



trivial solution만을 가질 때 **A의 각 열벡터**들은 선형독립

선형종속 (*Linearly Dependent*)

0이 아닌 상수 c 가 존재

1

공간 (Space)

선형독립과 선형종속

n개의 벡터에 대한 선형결합

$$c_1 x_1 + c_2 x_2 + \dots + c_n x_n = 0$$

선형독립 (*Linearly Independent*)

상수 c 가 모두 0인 경우를 제외한 어떠한 c_i 의 조합으로 식이 성립되지 않는 경우

$$c_1 = c_2 = \dots = c_n = 0$$



trivial solution만을 가질 때 **A의 각 열벡터**들은 선형독립

선형종속 (*Linearly Dependent*)

0이 아닌 상수 c 가 존재


1 공간 (Space)

선형독립과 선형종속

선형종속인 경우



2차원




$c_1v_1 + c_2v_2 = 0$ 는
 $c_1 = 2, c_2 = -1$ 일 때 성립



0벡터가 아닌 벡터 $c(2, -1)$ 에 의해 식 성립

3차원



(1,2,0) 처럼 (0,0,0) 이외에도 해가 존재



하나의 벡터를
다른 벡터의 조합으로 표현 가능

1


공간 (Space)

선형독립과 선형종속

선형독립인 경우



2차원




어떤 선형결합을 해도
c가 0인 경우를 제외하고는 0 만들 수 없음



벡터 v_1 과 v_2 는 독립

3차원



$(1,0,0)$ $(0,1,0)$ $(0,0,1)$ 로
0벡터가 유일한 해



벡터 x_1, x_2, x_3 는 선형독립

1

공간 (Space)

Rank

Rank

Col(A)에서 찾을 수 있는 Linearly independent한 벡터의 최대 개수

쉽게 생각하면 Column space의 차원!

EXAMPLE

$$\begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

Rank: 2


$$\begin{bmatrix} 2 & 2 \\ 1 & 1 \end{bmatrix}$$

Rank: 1


Rank

\mathbb{R}^n 공간에서 Linearly independent한 벡터의 최대 개수는 n 개

Rank



Linearly independent,
 w not in $\text{Span}\{u, v\}$



Linearly dependent,
 w in $\text{Span}\{u, v\}$

u, v 벡터가 linearly independent


→ 같은 직선 상에 위치 **X**

→ u 의 스칼라배로 v 를 만들 **X**


Rank

\mathbb{R}^n 공간에서 Linearly independent한 벡터의 최대 개수는 n 개

Rank



Linearly independent,
 w not in $\text{Span}\{u, v\}$



Linearly dependent,
 w in $\text{Span}\{u, v\}$

u, v 벡터가 linearly independent

→ 같은 직선 상에 위치 **X**

→ u 의 스칼라배로 v 를 만들 **X**



u, v 벡터가 선형독립

u, v 벡터로 파란색 평면 위의 **모든 표현 가능**

1


공간 (Space)

Rank

R^n 공간에서 Linearly independent한 벡터의 최대 개수는 n 개

Rank


평면 안에 있지 않은(독립) w 벡터를 잡아
세 벡터로 R^3 공간 전체 표현 가능!



Linearly independent,
 w not in $\text{Span}\{u, v\}$



Linearly dependent,
 w in $\text{Span}\{u, v\}$



Linearly independent,
 w not in $\text{Span}\{u, v\}$

상에 위치 X

로 v 를 만들 X

선형독립

의 모든 표현 가능

Rank

따라서...



A 행렬의 rank = A^T 행렬의 rank



Row(A)로 생성되는 벡터 공간의 차원

=

Col(A)으로 생성되는 벡터 공간의 차원

1

공간 (Space)

공간 형성 (Span)

공간 형성 (*Span*)

성분 a_1, a_2, \dots, a_n 의 모든 선형결합을 조합한 공간

앞서 선형부분공간이란...


벡터공간 안의 몇 가지 벡터의 집합으로 이루는 벡터공간 안의 또 다른 부분 벡터공간

1

공간 (Space)

공간 형성 (Span)

2차원




빨간색, 파란색 벡터 → 평면 공간만을 span

주황색 벡터가 평면에 추가된다면
빨간색 벡터와 파란색 벡터로 표현 가능

세 벡터로 span할 수 있는 공간은 여전히 평면 뿐

3차원



주황색 벡터가 평면 공간 밖에
있어야 R^3 공간 span 가능!


3차원 공간 형성

1

공간 (Space)

공간 형성 (Span)

2차원




빨간색, 파란색 벡터 → 평면 공간만을 span

만약 주황색 벡터가 추가된다면
빨간색 벡터와 파란색 벡터로 표현 가능

세 벡터로 span할 수 있는 공간은 여전히 평면 뿐

3차원



주황색 벡터가 평면 공간 밖에
있어야 R^3 공간 span 가능!

3차원 공간 형성

공간 형성 (Span)

그래서 이걸 왜 배운...?



$span$ 과 선형독립의 개념을 이용하여
기저(Basis)에 대해 알아보자!

1

공간 (Space)


기저 (Basis)

기저 (*Basis*)

어떤 공간을 구성하는 **span** 벡터의 최소 집합

기존 벡터들의 조합으로 설명되는 벡터를 추가하는 건 의미 X

→ 최소집합 등장



최소집합이란...

벡터 공간을 효율적으로, 최소한으로 표현할 수 있는 벡터들이 기저

1

공간 (Space)

기저 (Basis)

기저 (Basis)

어떤 공간을 구성하는 **span** 벡터의 최소 집합

기존 벡터들의 조합으로 설명되는 벡터(종속벡터)를 추가하는 건 의미 X

최소 집합: 벡터 공간을 효율적으로, 최소한으로 표현할 수 있는 벡터들이 기저



기저의 조건

- ① Linearly independent.
- ② 해당 벡터들이 V 공간을 span

그렇구나...



1


공간 (Space)

기저 (Basis)

기저의 예시




2차원



두 개의 벡터는 **선형독립**

\therefore 각 두 벡터가 R^2 공간의 basis가 됨.

3차원



세 개의 벡터는 **선형독립**

\therefore 각 세 벡터가 R^3 공간의 basis가 됨.

1

공간 (Space)

기저 (Basis)



Non-uniqueness of Basis

기저에서





2차원

$$R^2 \text{ 기저 벡터 : } \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

3차원

→ R^2 공간 span

가장 쉽게 생각할 수 있는 기저 벡터일 뿐, 유일한 것은 아님.



R^n 공간에서의 선형독립인 어느 n 개의 벡터든 R^n span 가능
 주황색 벡터를 추가
 세 개의 벡터는 선형독립
 어떤 공간을 span하는 기저 벡터는 유일 X
 선형독립의 가정을 위해
 \therefore 각 세 벡터가 R^3 공간의 basis가 됨.

1

공간 (Space)

기저 (Basis)와 rank의 관계

Example

1	4	3
2	1	1

이 공간의 기저 벡터 후보



1	4	3
2	1	1

선형결합으로 마지막 열 생성 가능


 \therefore 세 벡터는 linearly independent X

1	4	3
2	1	1

1,3번째 열 또한 basis 가능

1

공간 (Space)

기저 (Basis)와 rank의 관계

Example

1	4	3
2	1	1

이 공간의 기저 벡터 후보



1	4	3
2	1	1

선형결합으로 마지막 열 생성 가능



1	4	3
2	1	1

1,3번째 열 또한 basis 가능



어떤 basis를 잡더라도 그 개수는 동일

어떤 공간의 선형독립인 벡터의
최대 개수인 rank와 동일

2

노름과 내적

노름(Norms)

노름 (Norm)

벡터의 크기

$$\|\vec{v}\|_p = L_p = \sqrt[p]{|v_1|^p + |v_2|^p + \dots + |v_n|^p}$$


p = Norm의 차수

선형대수학에서는 위와 같이 정의

일반적으로 p=1인 L1 Norm과 p=2인 L2 Norm이 자주 사용됨


노름(Norms)



노름

 L_1 Norm

: 맨해튼 노름



각 벡터들의 **절댓값**을 합한 결과
Lasso Regression에서 사용

$$L_1 = |v_1| + |v_2| + \cdots + |v_n|$$

 L_2 Norm

: 유클리드 노름




원점에서 벡터가 연결된 **직선 거리**
Ridge Regression에서 사용

$$L_2 = \sqrt{|v_1|^2 + |v_2|^2 + \cdots + |v_n|^2}$$

자세한 내용은 회귀분석팀 클린업 참고

노름(Norms)



L_1 Norm (맨해튼 노름): — — —

L_2 Norm (유클리드 노름): —

⋮

주로 제약 조건 설정 시 많이 쓰임

자세한 내용은 회귀분석팀 클린업 참고

내적(Dot product)

내적 (Dot Product)

$$\textcircled{1} \quad x^T y = [x_1 \ x_2 \ \cdots \ x_n] \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = [x_1 y_1 + x_2 y_2 + \cdots + x_n y_n] = 0$$

$$\textcircled{2} \quad a \cdot b = \|a\| \|b\| \cos \theta$$

내적의 결과: 스칼라 값

$x^T y = x, y$ 벡터의 **각 성분을 곱한 것들의 합**

⋮

내적의 기하학 정의를 통해 두 벡터의 각도 θ 를 계산 가능

$$\theta = \cos^{-1}\left(\frac{a \cdot b}{\|a\| \|b\|}\right)$$

3

직교성

3 직교성 (Orthogonality)


직교성 (Orthogonality)

직교성 (Orthogonality)

두 벡터가 이루는 각도 θ 가 90° 가 되는 경우

두 벡터의 내적 = 0

$$a \cdot b = a^T b = 0$$



$$a \cdot b = \|a\| \|b\| \cos \theta$$

$\cos 90^\circ$ 거나 영벡터가 아닌 이상
0 될 수 없음

EXAMPLE

$$\begin{bmatrix} -1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} = -2 + 2 = 0$$

3 직교성 (Orthogonality)

직교성 (Orthogonality)

직교성 (Orthogonality)

두 벡터가 이루는 각이 90° 가 되는 경우



Space의 Orthogonality

$$a \cdot b = a^T b = 0$$



Subspace $S \perp$ Subspace T


$$a \cdot b = \|a\| \|b\| \cos \theta$$

=

S 안의 모든 벡터 \perp T 안의 모든 벡터

EXAMPLE


$$\begin{bmatrix} -1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} = -2 + 2 = 0$$



3 직교성 (Orthogonality)

직교성 (Orthogonality)

1차원 파란색 선 \perp 2차원 초록색 평면



1차원 선 \perp 2차원 평면

평면과 직선이 수직으로 만날 때 뿐!




초록색 평면에 어떤 벡터를 그려도
파란색 선 위의 모든 벡터와 수직

3 직교성 (Orthogonality)

직교집합 (Orthogonal set)

직교 집합 (*Orthogonal Set*)

서로 직교하는 벡터들의 집합



직교 집합의 벡터들은 서로 **선형 독립**
span으로 만들어지는 벡터공간의 **basis**가 됨.

3

직교성 (Orthogonality)

$Ax=b$ 의 해 구하기



배운 것들을 이용하여 $Ax=b$ 를 다시 한 번...

$$\begin{bmatrix} 1 & 1 & 2 \\ 3 & 1 & 0 \\ 2 & 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

$Ax = b$



$$x_1 \begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix} + x_2 \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} + x_3 \begin{bmatrix} 2 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

Linear Combination

3

직교성 (Orthogonality)

$Ax=b$ 의 해 구하기

“ $Ax=b$ 의 해(x)를 찾을 수 있다”



무슨 의미일까?

A 행렬의 Column의 Linear combination으로 b 벡터를 만들 수 있다

A의 Column space에 b가 있다

A 행렬을 통해 b 라는 벡터를 매핑 시킬 수 있는 x벡터를 찾을 수 있다.

1주차 선형변환의 원리!

3

직교성 (Orthogonality)

$Ax=b$ 의 해 구하기

“ $Ax=b$ 의 해(x)를 찾을 수 있다”



무슨 의미일까?

A 행렬의 Column의 Linear combination으로 b 벡터를 만들 수 있다

A의 Column space에 b가 있다

A 행렬을 통해 b 라는 벡터를 매핑 시킬 수 있는 x 벡터를 찾을 수 있다.

1주차 선형변환의 원리!

3

직교성 (Orthogonality)

$Ax=b$ 의 해 구하기

“ $Ax=b$ 의 해(x)를 찾을 수 있다”



무슨 의미일까?

A 행렬의 Column의 Linear combination으로 b 벡터를 만들 수 있다

A의 Column space에 b 가 있다

A 행렬을 통해 b 라는 벡터를 매핑 시킬 수 있는 x 벡터를 찾을 수 있다.

1주차 선형변환의 원리!

3

직교성 (Orthogonality)

$Ax=b$ 의 해 구하기



3X3 행렬 A의 Column Space 후보

영공간

3차원 공간

1차원
직선공간


2차원
평면공간

3 직교성 (Orthogonality)

$Ax=b$ 의 해 구하기



3X3 행렬 A의 Column Space 후보



행렬 A의 Column 모두 선형독립
3개의 벡터로 span 가능한 **최대 공간**

EXAMPLE

$$\begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix} \quad \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \quad \begin{bmatrix} 2 \\ 0 \\ 1 \end{bmatrix}$$

3 직교성 (Orthogonality)

$Ax=b$ 의 해 구하기



3X3 행렬 A의 Column Space 후보

A 행렬의 모든 column이

Linearly independent 하다

영공간

3차원 공간

1차원

직선공간

2차원

평면공간

A의 역행렬이 존재하며

A 행렬의 **rank** = column 벡터의 차원

행렬 A의 Column 모두 선형독립

$$\begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix}$$

$$\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

$$\begin{bmatrix} 2 \\ 0 \\ 1 \end{bmatrix}$$

3 직교성 (Orthogonality)

$Ax=b$ 의 해가 제한적인 경우

$$\begin{bmatrix} 1 & 1 & 2 \\ 1 & 0 & 1 \\ 1 & 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix} \quad \dashrightarrow \quad \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix}$$

1번째 Column + 2번째 Column = 마지막 Column



- ① Linearly Independent **X**
- ② 행렬 A의 Column 개수(3) \neq Basis의 개수(2)
(2차원 평면 밖의 벡터 표현 불가)

4

투영 (Projection)

4

투영 (Projection)

회귀식 (Regression Equation)

회귀식 (*Regression Equation*)

선형대수학의 $Ax = b$ 형태를 회귀식의 $X\beta = y$ 에 적용

$$y = X \beta$$

행렬의 형태로 표시한 경우

y : 실제 예측하고자 하는 종속변수

X : 독립변수들의 집합 X data

β : 각 변수들의 앞에 붙는 베타 계수

4

투영 (Projection)

Why 투영 (Projection)?

어떤 관계가 있는지 모르는 X 로 y 를 예측할 때

오차의 발생 불가피

오차를 최소화해야 함

$$Y = X\beta + \varepsilon$$



이런 상황에서 Projection

Y data를 최대한 표현할 수 있는 벡터 찾기!

4


투영 (Projection)

투영 (Projection)

벡터-벡터 Projection

한 벡터의 방향으로 만드는 직선 공간에 다른 벡터를 매핑 시키는 것
벡터 b 방향의 직선공간으로 공간 압축시키는 선형 변환

벡터를 projection 시키면 원래 벡터와의 차이가 생김



Error: 원래 벡터(a)와의 차이(a_2)

Error가 최소가 되도록 내리는 것이 Projection Vector


4

투영 (Projection)

투영 (Projection)

벡터-공간 Projection

벡터-벡터 투영에서 확장하여, 벡터를 투영시켰을 때 나오는 벡터와
원래 벡터 간의 **차이(error)를 최소화**하는 것



- ① b 를 $\text{col}(A)$ 평면에 투영하여 p 도출
- ② 벡터 a_1 과 a_2 의 선형결합으로 p 표현

⋮

error vector와 평면 **orthogonal**

4

투영 (Projection)


투영 (Projection)

벡터-공간 Projection

벡터-벡터 투영에서 확장하여, 벡터를 투영시켰을 때 나오는 벡터와
원래 벡터 간의 차이(error)를 최소화하는 것



최대한 근사한 해를 찾기 위해 최단거리로
열공간에 투영시켜 차원을 낮추는 투영의 원리 적용!



② 벡터 a_1 과 a_2 의 선형결합으로 p 표현



error vector와 평면 orthogonal

Projection의 회귀 적용

Projection으로 \hat{Y} 구하기

Y 벡터를 X의 Column Space로 Projection 시킨 벡터를 찾아 가장 근접한 해로 둬



$$X\beta = y$$

해를 찾을 수 없음, x Column Space 내에 y 가 없는 경우는?

$$X\hat{\beta} = \hat{y}$$

해를 찾을 수 있는 방정식으로 대체



가장 y 와 근사한 \hat{y} 를 기반으로 $\hat{\beta}$ 도출

4

투영 (Projection)

Projection의 회귀 적용

Projection으로 \hat{Y} 구하기

Y 벡터를 X의 Column Space로 Projection 시킨 벡터를 찾아 가장 근접한 해로 둬



$$X\beta = y$$

해를 찾을 수 없음 즉, x Column Space 내에 y 가 없는 경우는?

$$X\hat{\beta} = \hat{y}$$

해를 찾을 수 있는 방정식으로 대체

⋮

가장 y 와 근사한 \hat{y} 를 기반으로 $\hat{\beta}$ 도출

4


투영 (Projection)

Projection의 회귀 적용

모델의 목표

잔차가 평균이 0으로 회귀하는 정확한 모델을 만드는 것

Error 최소화 시키는 추정값 $\hat{\beta}$ 구하기



Error vector와 X의 Column Space의 **Orthogonality** 이용

4

투영 (Projection)

Projection의 회귀 적용

최적의 해를 구할 때 쓰이는 성질

$$\textcircled{1} e = y - \hat{y} = y - X\hat{\beta}$$

② error vector와 X의 Column Space는 Orthogonal

③ x vector의 모든 Column과의 내적값이 모두 0

해를 구하는 과정

$$X^T(y - X\hat{\beta}) = 0$$

$$X^T y = X^T X \hat{\beta}$$

$$(X^T X)^{-1} X^T y = \hat{\beta}$$



해를 도출할 수 있다!



$$X(X^T X)^{-1} X^T y = X\hat{\beta} = \hat{y}$$

4

투영 (Projection)

Projection의 회귀 적용

최적의 해를 구할 때 쓰이는 성질

- ① $e = y - \hat{y} = y - X\hat{\beta}$
- ② error vector와 X의 Column Space는 Orthogonal
- ③ x vector의 모든 Column과의 내적값이 모두 0

해를 구하는 과정

$$X^T(y - X\hat{\beta}) = 0$$

$$X^T y = X^T X \hat{\beta}$$

$$(X^T X)^{-1} X^T y = \hat{\beta}$$



해를 도출할 수 있다!



$$X(X^T X)^{-1} X^T y = X\hat{\beta} = \hat{y}$$

Projection 변환을 가하는

Projection Matrix

5

회귀적용

잔차제곱을 최소화하는 β 계수 찾기 β 값 찾기① 회귀식 $y = \beta_0 + \beta_1 x$ 를 $X\beta = y$ 형태로 바꿈 ($Ax = b$)② $Ax=b$ 에서 해를 찾을 수 있는 방정식 $A\hat{x} = \hat{y}$ 으로 대체

Predicted Y value	Observed Y value
$\beta_0 + \beta_1 x_1$	y_1
\vdots	\vdots
$\beta_0 + \beta_1 x_n$	y_n

$$X\beta = y, \text{ where } X = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}, \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

예측값 \neq 실제값 $\rightarrow X\beta = y$ 은 해가 존재 안함

잔차제곱을 최소화하는 β 계수 찾기 β 값 찾기① 회귀식 $y = \beta_0 + \beta_1 x$ 를 $X\beta = y$ 형태로 바꿈 ($Ax = b$)② $Ax=b$ 에서 해를 찾을 수 있는 방정식 $A\hat{x} = \hat{y}$ 으로 대체

Least-Square method를 사용!

 $X\beta$ 와 y 의 최소 거리인 간접해를 구함

Predicted value	Observed value
$\beta_0 + \beta_1 x_1$	y_1
\vdots	\vdots
$\beta_0 + \beta_1 x_n$	y_n

$$X\beta = y, \text{ where } X = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}, \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

예측값 \neq 실제값 $\rightarrow X\beta = y$ 은 해가 존재 안함

잔차제곱을 최소화하는 β 계수 찾기

최소제곱법 (Least Square Estimator Method)

y_i 와 회귀선 위의 \hat{y} 값의 거리의 제곱합이 **최소가 되도록** 하는 추정치를 찾는 방법
다중선형회귀에서는 행렬을 이용

$$\begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} \hat{a} \\ \hat{b} \end{pmatrix} = \begin{pmatrix} \widehat{y_1} \\ \widehat{y_2} \\ \widehat{y_3} \end{pmatrix} \quad \text{추정치}$$

β 값 찾기

- ① 회귀식 $y = \beta_0 + \beta_1 x$ 를 $X\beta = y$ 형태로 바꿈 ($Ax = b$)
- ② $Ax=b$ 에서 해를 찾을 수 있는 방정식 $A\hat{x} = \hat{y}$ 으로 대체

$$\left. \begin{array}{l} A^T A x = A^T b \\ X^T X \beta = X^T y \end{array} \right\} \text{해 } (x, \beta) \text{를 찾을 수 있음}$$

잔차제곱을 최소화하는 β 계수 찾기

최소제곱법 (Least Square Estimator Method)

y_i 와 회귀선 위의 y 값의 거리의 제곱합이 **최소가 되도록** 하는 추정치를 찾는 방법
다중선형회귀에서는 행렬을 이용

$$\begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} \hat{a} \\ \hat{b} \end{pmatrix} = \begin{pmatrix} \widehat{y_1} \\ \widehat{y_2} \\ \widehat{y_3} \end{pmatrix} \quad \text{추정치}$$

β 값 찾기

- ① 회귀식 $y = \beta_0 + \beta_1 x$ 를 $X\beta = y$ 형태로 바꿈 ($Ax = b$)
- ② $Ax=b$ 에서 해를 찾을 수 있는 방정식 $A\hat{x} = \hat{y}$ 으로 대체

$$\left. \begin{array}{l} A^T A \hat{x} = A^T \hat{b} \\ X^T X \hat{\beta} = X^T \hat{y} \end{array} \right\} \text{해 } (\hat{x}, \hat{\beta}) \text{를 찾을 수 있음}$$

가중회귀모델

단순선형회귀식 (Linear Regression)

$$y_i = \beta_0 + \beta_1 x_1 + \epsilon_i$$

오차항 (residual)

$$\epsilon_i \sim N(0, \sigma^2)$$


입력 변수와 무관하게 무작위적으로 분포한 등분산성 가정

→ ϵ_i 의 분산이 일정하면 더 정확한 오차 계산과 예측 가능

하지만 등분산성 가정을 만족하지 않을 때...

가중선형회귀

단순선형회귀식 (Linear Regression)



작은 분산에 가중치를 두어 등분산성을 맞춰 처리

하지만 등분산성 가정을 만족하지 않을 때...

가중회귀모델



가중선형회귀

가중선형회귀 (Weighted Linear Regression)

양변에 각각 가중치를 곱한 후 Least-square problem을 적용해 베타 계수 추정

가중치: 해당 관측치의 분산의 역수

$$\begin{pmatrix} W_1 & 0 & \dots & 0 \\ 0 & W_2 & \dots & 0 \\ \vdots & 0 & \ddots & \vdots \\ 0 & 0 & \dots & W_n \end{pmatrix} \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} = \begin{pmatrix} W_1 & 0 & \dots & 0 \\ 0 & W_2 & \dots & 0 \\ \vdots & 0 & \ddots & \vdots \\ 0 & 0 & \dots & W_n \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

⋮

잔차의 분산이 다르기 때문에 등분산성이 성립 X

가중치를 곱한다면 분산이 큰 잔차는 값을 작게 만들고, 작은 잔차는 값을 크게 만듦

가중치가 조정 파라미터의 역할을 함

가중선형회귀

가중선형회귀 (*Weighted Linear Regression*)

양변에 각각 가중치를 곱한 후 Least-square problem을 적용해 베타 계수 추정

$$\begin{array}{c}
 \text{가중치} \\
 \left(\begin{array}{cccc} W_1 & 0 & \dots & 0 \\ 0 & W_2 & \dots & 0 \\ \vdots & 0 & \ddots & \vdots \\ 0 & 0 & \dots & W_n \end{array} \right) \left(\begin{array}{c} 1 \\ 1 \\ \vdots \\ 1 \end{array} \begin{array}{c} x_1 \\ x_2 \\ \vdots \\ x_n \end{array} \right) \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} = \left(\begin{array}{cccc} W_1 & 0 & \dots & 0 \\ 0 & W_2 & \dots & 0 \\ \vdots & 0 & \ddots & \vdots \\ 0 & 0 & \dots & W_n \end{array} \right) \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}
 \end{array}$$

⋮

일반 선형회귀 계수 추정

$$\begin{aligned}
 X^T X \beta &= X^T y \\
 \hat{\beta} &= (X^T X)^{-1} X^T y
 \end{aligned}$$

가중선형회귀 계수 추정


$$\begin{aligned}
 (WX)^T WX \beta &= (WX^T) W y \\
 \hat{\beta} &= (WX^T X)^{-1} (WX)^T y
 \end{aligned}$$

구조가 유사함을 확인



가중선형회귀

가중선형회귀선이 단순선형회귀선보다 실제 회귀선에 더 근접




가중선형회귀가 단순선형회귀보다 유연함

→ 절대적인 것은 아니다

가중선형회귀

IT v SP 5-10-20 spread, with regression lines




Current point(●): 실제 관측값

단순선형회귀가 예측을 더 정확하게 해냄.

데이터에 따라 성능이 다를 수 있음

가중선형회귀

IT v SP 5-10-20 spread, with regression lines



Current point(●): 실제 관측값

단순선형회귀가 예측을 더 정확하게 해냄.

데이터에 따라 성능이 다를 수 있음

⋮

각 관측치의 분산을 구하기 어려운 경우가 많음


실제로 가중선형회귀를 적용하긴 쉽지 않음

변수변환 같은 해결책 사용

자세한 내용은 회귀분석팀 클린업 참고

가중선형회귀

IT v SP 5-10-20 spread, with regression lines



✓ 선형회귀, 가중회귀, 베타계수식, 잔차제곱합 비교

	일반회귀	가중회귀
SSE	$\ y - \hat{y}\ = \ y - X\hat{\beta}\ ^2$	$\ Wy - W\hat{y}\ = \ Wy - WX\hat{\beta}\ ^2$
β 의 해	$X^T X \hat{\beta} = X^T y$	$(WX)^T WX \hat{\beta} = (WX)^T Wy$

Current point(●): 실제 관측값

가중선형회귀가 예측을 더 정확하게 해냄.

각 관측치의 분산을 구하기 어려운 경우가 많음

실제로 가중선형회귀를 적용하긴 쉽지 않음

변수변환 같은 해결책 사용

다음 주 예고

1. 고유값과 고유벡터
2. 고유값 분해
3. 주성분분석
4. 특이값분해